

智能渗透 Agent 能力测评报告

(第一期)

测评时间：2026 年 Q2

基于 TSecBench 统一评测体系，对国内外代表性智能渗透 Agent 与国内主流大语言模型开展组合评测，并以每个 Agent×模型组合三轮测试中的最高成功率结果，观察能力上限、系统适配与效能差异。

领先模型

77.03%

Kimi K3



最高组合结果

90.54%

T3MP3ST / Cairn + Kimi K3



52 组合总体

67.52%

各组合三轮成功率取最高



共同短板

29.53%

多阶段渗透



测评背景与目的

大语言模型正在从“给出安全建议”走向“自主规划、调用工具并完成攻击链”的智能渗透 Agent。不同 Agent 在任务分解、工具编排、上下文管理、记忆、监督纠偏和结果验证方面差异显著；同一 Agent 接入不同模型后，也会呈现明显的能力与资源差异。仅依靠项目演示或单次案例，难以对系统的真实能力做横向比较。

为什么需要统一测评

在相同题集、环境、流程和评分规则下比较 Agent 与模型组合，尽量排除调度策略、答题顺序和外部环境差异对结果的干扰。

本报告关注什么

聚焦 Agent、模型及二者组合的最高公开成功率、耗时、Token 与六大能力域表现，为技术研究和方案选型提供数据参考。

TSecBench 的定位

由腾讯安全云鼎实验室推出，面向自动化红队与对抗性 AI，通过真实漏洞、生产级靶场和云原生环境衡量自主渗透能力。

公开透明与可复现

平台持续扩展榜单，并逐步公开完整测评日志及大模型对话记录；详细结果与 Agent Trace 统一在官网查看。

评测方式与统计口径

TSecBench v1 共 63 道题，覆盖 Web 漏洞挖掘、二进制漏洞挖掘、漏洞利用、多阶段渗透、云攻击和对抗规避六大能力域。本次公开数据包含 13 个 Agent、4 个模型（Kimi K3、GLM 5.2、DeepSeek-V4-Pro-Preview、MiniMax M3）、每个组合 3 轮，共 156 份结果。所评测的模型对象即上述四款在评测期间的对应版本，不包含此后发布的新模型或模型新版本。

01 单题独立

采用单题依次评测，每道题独立运行。

02 时间限制

一般题目最长运行 1 小时；多阶段渗透为特例，最长运行 2 小时；超时视为未通过。

03 统一条件

统一环境、配置、流程和评分规则。

04 三轮取优

每个 Agent × 模型组合选成功率最高的一轮。

05 指标汇总

仅以 52 个选定结果重算所有报告指标。

“ 并列处理

若三轮最高成功率相同，依次选择总耗时更短、总 Token 更少、轮次更早的结果。该口径用于观察组合的公开能力上限，不代表典型运行均值。详细题目过程、原始结果与 Agent Trace 请访问 [TSecBench 官网](#)。

核心结论

Kimi K3 的组合上限最强

13 个 Agent 的选定结果汇总成功率为 77.03%，在 11 个 Agent 内取得该 Agent 的最高模型组合成绩。

Cairn 的跨模型上限最高

四个模型各取最优轮次后，汇总成功率达到 77.70%，在 13 个 Agent 中排名第一。

最高组合结果并列 90.54%

T3MP3ST + Kimi K3 与 Cairn + Kimi K3 均达到 90.54%；前者选定结果耗时更短。

长链任务仍是核心瓶颈


即使各组合都取三轮最优，多阶段渗透成功率仍仅 29.53%，完整解题率为 8.33%。

智能渗透 Agent 效能对比

每个 Agent 汇总四个模型组合各自选定的最优轮次，用于比较其跨模型能力上限与资源表现。

Agent 平均成功率排名

四模型最优轮次结果汇总



Agent 效能指标

按平均成功率降序

排名	Agent	平均成功率	完整解题率	平均耗时	平均 Token
1	 Cairn	77.70%	82.14%	22.11 h	458.50 M
2	 CHYing	75.00%	80.56%	22.78 h	27.92 M
3	 LuaNlao	74.32%	80.95%	23.39 h	261.66 M
4	 BreachWeave	73.65%	78.97%	21.05 h	266.96 M
5	 Claude Code	72.30%	76.59%	18.03 h	58.42 M
6	 CyberStrikeAI	71.96%	77.38%	15.92 h	145.82 M
7	 T3MP3ST	70.61%	75.79%	20.38 h	230.80 M
8	 cai	67.91%	74.21%	25.66 h	140.59 M
9	 pi	67.57%	73.81%	16.43 h	158.70 M
10	 shannon	63.85%	65.87%	31.31 h	23.92 M
11	 Pentagi	61.15%	68.65%	31.17 h	128.58 M
12	 ctfSolver	55.74%	63.10%	31.15 h	262.27 M
13	 PentestAgent	45.95%	52.78%	35.92 h	223.02 M

Agent × 模型组合成功率

每格仅显示该组合三轮中的最高成功率；深色代表更高

低 高

	DeepSeek-V4-Pro-Preview	GLM 5.2	Kimi K3	MiniMax M3
Cairn	73.0%	78.4%	90.5%	68.9%
CHYing	66.2%	79.7%	85.1%	68.9%
LuaNlao	68.9%	82.4%	75.7%	70.3%
BreachWeave	68.9%	75.7%	86.5%	63.5%
Claude Code	66.2%	75.7%	81.1%	66.2%
CyberStrikeAI	68.9%	71.6%	82.4%	64.9%
T3MP3ST	64.9%	67.6%	90.5%	59.5%
cai	67.6%	77.0%	68.9%	58.1%
pi	60.8%	71.6%	81.1%	56.8%
shannon	58.1%	67.6%	70.3%	59.5%
Pentagi	59.5%	62.2%	68.9%	54.0%
ctfSolver	51.4%	58.1%	63.5%	50.0%
PentestAgent	37.8%	46.0%	56.8%	43.2%

52 个 Agent × 模型最优结果

每行对应一个 Agent × 模型组合的三轮最高成功率结果，并按成功率降序排列。详细结果和 Agent Trace 请在官网查看。

排名	Agent / GitHub	模型	成功率	完整解题率	总耗时	Token	评测单位
1	T3MP3ST	Kimi K3	90.54%	93.65%	14.49 h	74.32 M	武汉大学
2	Cairn	Kimi K3	90.54%	93.65%	18.39 h	215.08 M	武汉大学
3	BreachWeave	Kimi K3	86.49%	88.89%	16.00 h	69.08 M	四川大学
4	CHYing	Kimi K3	85.14%	88.89%	17.85 h	15.78 M	四川大学
5	CyberStrikeAI	Kimi K3	82.43%	88.89%	18.69 h	98.03 M	鹏城实验室
6	LuaNlao	GLM 5.2	82.43%	85.71%	20.71 h	195.91 M	鹏城实验室
7	Claude Code	Kimi K3	81.08%	85.71%	15.78 h	15.91 M	清华大学
8	pi	Kimi K3	81.08%	84.13%	17.28 h	82.00 M	清华大学
9	CHYing	GLM 5.2	79.73%	82.54%	23.98 h	19.69 M	四川大学
10	Cairn	GLM 5.2	78.38%	80.95%	22.14 h	387.82 M	武汉大学
11	cai	GLM 5.2	77.03%	80.95%	22.40 h	140.79 M	四川大学
12	Claude Code	GLM 5.2	75.68%	80.95%	15.48 h	10.53 M	清华大学
13	BreachWeave	GLM 5.2	75.68%	80.95%	19.79 h	164.81 M	四川大学
14	LuaNlao	Kimi K3	75.68%	80.95%	22.70 h	182.87 M	鹏城实验室
15	Cairn	DeepSeek-V4-Pro-Preview	72.97%	79.37%	23.77 h	530.19 M	武汉大学
▼							

排名	Agent / GitHub	模型	成功率	完整解题率	总耗时	Token	评测单位
16	pi	GLM 5.2	71.62%	77.78%	16.36 h	93.24 M	清华大学
17	CyberStrikeAI	GLM 5.2	71.62%	73.02%	16.90 h	126.77 M	鹏城实验室
18	shannon	Kimi K3	70.27%	76.19%	27.86 h	43.76 M	四川大学
19	LuaNlao	MiniMax M3	70.27%	80.95%	29.96 h	391.22 M	鹏城实验室
20	CyberStrikeAI	DeepSeek-V4-Pro-Preview	68.92%	76.19%	14.99 h	187.94 M	鹏城实验室
21	LuaNlao	DeepSeek-V4-Pro-Preview	68.92%	76.19%	20.18 h	276.64 M	鹏城实验室
22	BreachWeave	DeepSeek-V4-Pro-Preview	68.92%	77.78%	22.47 h	408.76 M	四川大学
23	CHYing	MiniMax M3	68.92%	79.37%	23.07 h	60.41 M	四川大学
24	Cairn	MiniMax M3	68.92%	74.60%	24.12 h	700.91 M	武汉大学
25	cai	Kimi K3	68.92%	74.60%	24.79 h	87.17 M	四川大学
26	Pentagi	Kimi K3	68.92%	74.60%	35.42 h	50.61 M	武汉大学
27	T3MP3ST	GLM 5.2	67.57%	71.43%	19.40 h	234.59 M	武汉大学
28	cai	DeepSeek-V4-Pro-Preview	67.57%	76.19%	24.94 h	122.50 M	四川大学
29	shannon	GLM 5.2	67.57%	68.25%	29.89 h	15.02 M	四川大学
30	Claude Code	DeepSeek-V4-Pro-Preview	66.22%	69.84%	18.81 h	57.05 M	清华大学
31	Claude Code	MiniMax M3	66.22%	69.84%	22.05 h	150.21 M	清华大学
32	CHYing	DeepSeek-V4-Pro-Preview	66.22%	71.43%	26.21 h	15.82 M	四川大学



排名	Agent / GitHub	模型	成功率	完整解题率	总耗时	Token	评测单位
33	CyberStrikeAI	MiniMax M3	64.86%	71.43%	13.09 h	170.54 M	鹏城实验室
34	T3MP3ST	DeepSeek-V4-Pro-Preview	64.86%	71.43%	23.66 h	258.74 M	武汉大学
35	BreachWeave	MiniMax M3	63.51%	68.25%	25.93 h	425.19 M	四川大学
36	ctfSolver	Kimi K3	63.51%	69.84%	31.77 h	235.37 M	武汉大学
37	Pentagi	GLM 5.2	62.16%	71.43%	26.31 h	96.34 M	武汉大学
38	pi	DeepSeek-V4-Pro-Preview	60.81%	68.25%	15.20 h	206.15 M	清华大学
39	T3MP3ST	MiniMax M3	59.46%	66.67%	23.96 h	355.56 M	武汉大学
40	Pentagi	DeepSeek-V4-Pro-Preview	59.46%	66.67%	29.18 h	203.75 M	武汉大学
41	shannon	MiniMax M3	59.46%	58.73%	34.40 h	22.11 M	四川大学
42	ctfSolver	GLM 5.2	58.11%	68.25%	28.66 h	210.53 M	武汉大学
43	cai	MiniMax M3	58.11%	65.08%	30.50 h	211.89 M	四川大学
44	shannon	DeepSeek-V4-Pro-Preview	58.11%	60.32%	33.11 h	14.80 M	四川大学
45	pi	MiniMax M3	56.76%	65.08%	16.89 h	253.39 M	清华大学
46	PentestAgent	Kimi K3	56.76%	66.67%	39.38 h	150.54 M	鹏城实验室
47	Pentagi	MiniMax M3	54.05%	61.90%	33.76 h	163.62 M	武汉大学
48	ctfSolver	DeepSeek-V4-Pro-Preview	51.35%	57.14%	32.99 h	234.81 M	武汉大学
49	ctfSolver	MiniMax M3	50.00%	57.14%	31.19 h	368.36 M	武汉大学
▼							

排名	Agent / GitHub	模型	成功率	完整解题率	总耗时	Token	评测单位
50	PentestAgent	GLM 5.2	45.95%	52.38%	39.54 h	285.37 M	鹏城实验室
51	PentestAgent	MiniMax M3	43.24%	47.62%	37.29 h	251.55 M	鹏城实验室
52	PentestAgent	DeepSeek-V4-Pro-Preview	37.84%	44.44%	27.47 h	204.62 M	鹏城实验室

详细题目矩阵、逐轮结果及 Agent Trace：[TSecBench 官网](#)

Agent 与模型的场景适应性

能力域分析仅使用 52 个选定结果。题号到能力域的映射依据 TSecBench v1 各能力域题量与本地题号前缀对应关系。

Agent × 六大能力域

每个 Agent 汇总四个模型的选定结果


低 高




	Web漏洞挖掘	二进制漏洞挖掘	漏洞利用	多阶段渗透	云攻击	对抗规避
cai	75.0%	80.8%	55.6%	26.8%	83.3%	89.3%
pi	70.8%	80.8%	36.1%	26.8%	95.8%	100.0%
shannon	73.6%	42.3%	38.9%	42.9%	95.8%	94.6%
Pentagi	66.7%	75.0%	38.9%	14.3%	95.8%	87.5%
ctfSolver	62.5%	71.2%	13.9%	10.7%	87.5%	91.1%
PentestAgent	38.9%	67.3%	25.0%	5.4%	75.0%	76.8%

成功率 vs 选定结果耗时（按模型拆分）


每格一个模型；点=Agent（直接标注），纵轴成功率(%)、横轴耗时(小时，按本模型数据自适应缩放)




GLM 5.2



DeepSeek-V4-Pro-Preview




MiniMax M3




成功率 vs 选定结果 Token（按模型拆分）

每格一个模型；点=Agent（直接标注），纵轴成功率(%)、横轴 Token(M，按本模型数据自适应缩放)


Kimi K3




GLM 5.2



DeepSeek-V4-Pro-Preview





Agent 工程定位与 GitHub 仓库

仓库地址按用户提供信息统一修正。表格按每个 Agent 在四个模型组合中的最高成功率降序排列；架构摘要来自当前公开资料，不能证明与测评时提交、提示词、工具及启用模式完全一致。

Agent	GitHub 仓库	项目定位与架构（据 GitHub README）	最高成功率
T3MP3ST	github.com/elder-plinius/T3MP3ST ↗	多智能体自动化红队框架，编排侦察→扫描→利用→持久化等专职操作员，驱动 AI 编码助手完成授权渗透。	90.54% Kimi K3
Cairn	github.com/oritera/Cairn ↗	通用状态空间搜索引擎，采用黑板架构与「事实-意图图」驱动多 Agent 协作求解渗透测试等问题。	90.54% Kimi K3
BreachWeave	github.com/m-sec-org/BreachWeave ↗	采用 Manager / Solver / Observer 多角色协作架构的自主渗透测试 Agent 系统。	86.49% Kimi K3
CHYing	github.com/yhy0/CHYing-agent ↗	Orchestrator 模式渗透测试 Agent，经 MCP 工具调度执行、浏览器、C2、逆向等子 Agent 协同作业。	85.14% Kimi K3

Agent	GitHub 仓库	公开工程定位 / 架构摘要	最高成功率
CyberStrikeAI	github.com/EdIsOnZ/CyberStrikeAI ↗	AI 原生安全测试平台，融合 Eino 代理、MCP 工具、知识库与可视化工作流，支持多智能体编排、人工审批与审计追踪。	82.43% Kimi K3
LuaNlao	github.com/SanMuzZzZz/LuaNlaoAgent ↗	图认知推理的自主渗透测试 Agent，采用「规划者-执行者-观察者」三角架构，结合因果推理图、证据溯源与动态任务图。	82.43% GLM 5.2
Claude Code	github.com/anthropics/claude-code ↗	运行于终端的 AI 编程代理，理解代码库并以自然语言命令执行开发任务、解释代码、处理 Git 工作流。	81.08% Kimi K3
pi	github.com/earendil-works/pi ↗	模块化 AI 智能体工具包：统一多模型 LLM 接口、带工具调用与状态管理的代理运行时、交互式编码代理 CLI。	81.08% Kimi K3
cai	github.com/aliasrobotics/cai ↗	轻量级开源安全自动化框架，多代理架构，通过链式推理与工具集成实现网络攻防自动化。	77.03% GLM 5.2
shannon	github.com/KeygraphHQ/shannon ↗	自主 AI 渗透测试工具，通过源码分析与真实漏洞利用为 Web 应用与 API 做安全测试。	70.27% Kimi K3
Pentagi	github.com/vxcontrol/pentagi ↗	完全自主的 AI 多代理系统，可自托管、支持多种大模型，用于执行复杂渗透测试任务。	68.92% Kimi K3
ctfSolver	github.com/passers-W/ctfSolver ↗	基于 AI 的 CTF 自动解题平台，五类 Agent 协同，集页面探索、漏洞扫描与智能解题于一体。	63.51% Kimi K3
PentestAgent	github.com/GH05TCREW/PentestAgent ↗	支持 Assist / Agent / Crew 多模式的 AI 渗透测试框架，LLM 驱动、MCP 扩展、工具编排。	56.76% Kimi K3

免责声明与使用说明

- 1. 时效与版本：本报告仅反映测评期间所用的模型版本与各 Agent 当时提交的实现，不包含此后发布的新模型或模型新版本；模型与 Agent 持续迭代，实际能力可能与本报告存在差异。
- 2. 能力上限口径：成绩按“每个 Agent×模型组合三轮取最高成功率”统计，不代表典型或平均表现。
- 3. 影响因素：结果受提示词、工具与配置、运行环境、题目、超时上限及模型输出随机性等影响，个别数据点可能因超时中断等运行事实而波动。
- 4. 用途：本报告仅供技术与方案选型参考，不构成对任何模型、Agent 或厂商的排名背书、商业承诺或保证，亦不代表官方结论。
- 5. 合规：全部测评均在授权、受控的靶场环境中进行。

评测单位

本次公开测评结果
由以下单位完成

